



ANALYSE DES PRIX IMMOBILIERS

Du modèle linéaire aux
méthodes de régularisation

Edouard Lacroix – Elise Prigent

Université Paris 1 Panthéon-Sorbonne
Sorbonne Data Analytics – Année 2025/2026

CONTEXTE & OBJECTIFS

Contexte économique

Le marché immobilier joue un rôle central dans l'économie, tant pour les ménages que pour les investisseurs et les décideurs publics.

Objectif de l'étude

Identifier les déterminants des prix immobiliers et évaluer l'apport des méthodes économétriques avancées pour améliorer la robustesse et la performance prédictive des modèles.

DONNÉES & ÉCHANTILLON

- L'étude repose sur un échantillon de 150 transactions immobilières.

Variables principales

Prix de vente (K€)	Surface habitable (m2)	Nombre de chambres	Distance au centre-ville (km)
Étage	Ascenseur	Qualité des écoles	Revenu médian du quartier (k€)

Ces données permettent une analyse conjointe des caractéristiques physiques et socio-économiques.

ANALYSE DESCRIPTIVE

```
Statistiques pour Prix_milliers_euros :
moyenne          2107.904800
mediane          2105.050000
ecart_type       229.921013
minimum          1500.770000
Q1               1934.285000
Q2 (mediane)     2105.050000
Q3               2272.780000
maximum          2743.040000
Asymetrie (skewness)  0.154664
Applatissement (kurtosis) -0.492978
dtype: float64
```

Distribution des prix :

- Forte **dispersion** des prix immobiliers
- Asymétrie **positive** marquée


Conséquence économétrique :

- La distribution justifie l'utilisation d'une **transformation logarithmique** du prix afin de stabiliser la variance et améliorer l'ajustement du modèle.

ANALYSE DE CORRÉLATION

Résultats clés :

- Corrélation Surface / Prix ≈ 0.83
- Corrélation **négative** entre distance au centre et prix
- Effets **positifs** modérés des variables de quartier



La surface apparaît comme le principal moteur du prix, mais n'est pas suffisante seule.

MODÈLE LINÉAIRE SIMPLE (MCO)

$$Prix_i = \beta_0 + \beta_1 \times Surface_i + u_i$$

SPÉCIFICATIONS

Le prix est expliqué uniquement par la **surface habitable**.



RÉSULTATS

Effet **positif** et hautement significatif de la surface
 $R^2 \approx 0,68$



LIMITE

Le modèle souffre d'un **biais de variables omises**.

MODÈLE LINÉAIRE MULTIPLE

$$\text{Prixi} = \beta_0 + \beta_1 \times \text{Surfacei} + \beta_2 \times \text{Chambresi} + \beta_3 \times \text{Annee_constructioni} \\ + \beta_4 \times \text{Distance_centrei} + \beta_5 \times \text{Etagei} + \beta_6 \times \text{Ascenseur} + u_i$$

Extension du modèle :

- Ajout des caractéristiques structurelles et de localisation.

Résultats :

- **Amélioration** significative du pouvoir explicatif
- R^2 ajusté $\approx$ **0.78**
- Variables clés **toutes** significatives

Test F d'ajout (Qualité école, Revenu quartier) :

- $F =$ **29.3**, $p <$ **0,001** / R^2 ajusté $\approx$ **0.78**
- Amélioration significative du modèle

Le modèle permet une interprétation toutes choses égales par ailleurs

CARACTÉRISTIQUES	COEFFICIENT	P-VALUE
Surface_m2	4.3879	0.000
Chambres	33.9205	0.001
Annee_construction	1.6093	0.037
Distance_centre_km	-6.1446	0.000
Etage	12.254	0.016
Ascenseur	55.5141	0.002

Adj. R-squared	0.78
----------------	------

CHOIX DE LA FORME FONCTIONNELLE

Modèles comparés :


- Linéaire Multiple
- Log-log
- Semi-logarithmique

Résultat :


Le modèle semi-logarithmique présente :

- Le meilleur **R^2 ajusté**
- Les critères **AIC** et **BIC** les plus faibles

R2 Ajusté par modèle



AIC/BIC par modèle



INTERPRÉTATION ÉCONOMIQUE

+1 mètre carré (m²)



+0,21 % sur le prix

Présence d'un ascenseur



+2,6 % sur le prix

Distance au centre



Effet négatif significatif

L'interprétation en variations relatives est particulièrement adaptée au marché immobilier.

DIAGNOSTICS ÉCONOMÉTRIQUES

MULTICOLINÉARITÉ

VIF

< 2 pour toutes
variables

HÉTÉROSCÉDASTICITÉ

Breusch-Pagan

NON
SIGNIFICATIF

Les hypothèses des MCO sont respectées

Impact du COVID-19

Rupture
Structurelle

Après
COVID-19

Point de Rupture

Prix de l'immobilier

Test de
Chow

Test de Chow en Économétrie

STABILITÉ STRUCTURELLE

Test de Chow :

- Chow F-statistic : 8.7169
- Chow p-value : 3.3287e-10
- Rejet de H_0 : il y a une rupture structurelle significative en 2020.

Interprétation :

- La pandémie de **COVID-19** a **modifié** les déterminants des prix immobiliers, remettant en cause la stabilité des coefficients dans le temps.

ENDOGENÉITÉ : QUALITÉ DES ÉCOLES



RISQUE IDENTIFIÉ

- Variables omises
- Simultanéité potentielle



MÉTHODE

Utilisation d'une variable instrumentale :
distance à l'université.

TESTS D'ENDOGÉNÉITÉ

- H_0 : absence d'endogénéité
- H_1 : présence d'endogénéité
- Si $p\text{-value} > 5\%$ → H_0 non rejetée
- Si $p\text{-value} \leq 5\%$ → H_0 rejetée

Résultats :

- Instrument fort (statistique $F > 10$)
- Test de Durbin–Wu–Hausman non significatif ($p\text{-value} = 0.196$)

L'hypothèse d'exogénéité n'est pas rejetée : le modèle **MCO** est conservé



POURQUOI LA RÉGULARISATION ?

PROBLÉMATIQUE

Le modèle MCO peut souffrir de **sur-apprentissage**.


OBJECTIFS

Réduire la **variance** des coefficients



Améliorer la **performance** hors-échantillon

MÉTHODES

Ridge & Lasso



LASSO VS RIDGE



Lasso :

- Quand λ augmente : coefficients **fortement pénalisés**.
- Dans notre cas, dès que λ devient modéré, tous les coefficients sont ramenés à **zéro**.
- Ne conserve **aucune variable** explicative

Ridge :

- Quand λ augmente : coefficients diminuent en **valeur absolue**
- Les variables influentes voient leur coefficient se **réduire plus**
- **Stabilisation** des estimations et limitation de la multicolinéarité

Le Ridge offre le meilleur compromis biais / variance.

PERFORMANCE PRÉDICTIVE (RMSE)

MCO



LASSO



RIDGE




Le modèle **Ridge** minimise l'erreur de prédiction hors-échantillon.

PRÉVISION IMMOBILIÈRE (MCO)

Caractéristiques

- Surface : **120 m2**
- Chambres : **3**
- Année construction : **2015**
- Distance centre : **5 km**
- Étage : **1**
- Ascenseur : **Oui**
- Qualité école : **7**
- Revenu médian quartier : **65 000 €**



Prédictions :

- Prix prédit $\approx$ **2.26 M€**
- IC 95 % : **[2,22 ; 2,30] M€**

CONCLUSION

- Modèle économétriquement **valide** et **robuste**
- **Rupture structurelle** post-COVID confirmée
- Apport réel des méthodes de **régularisation**
- Outil pertinent pour l'analyse et la **prévision immobilière**

MERCI POUR VOTRE ATTENTION !

DES QUESTIONS ?